

BIST MINI-2 PROJECT

웹 서비스 및 RAG 기반 AI 솔루션

연구자 및 R&D 센터를 위한

맞춤형 AI 공동 연구 파트너 플랫폼

비스텔리전스 채용연계형 1기 2차 미니프로젝트

Wrap-Up Report | 2026. 06. 30

김지환, 신동원, 천승현

2026. 06. 30

프로젝트 개요 및 개발 마일스톤

핵심 비전

“연구자 및 R&D 센터를 위한 맞춤형 AI 공동 연구 파트너”

파편화된 학술 데이터와 실시간 웹 동향을 단일 지능형 컨텍스트로 통합하여 단순 자료 조사 비용을 줄이고 본연의 연구 생산성을 극대화합니다.

팀 역할 분담

• 김지환

컴퓨터 과학 분야 RAG 파이프라인 구현 & 대규모 문헌 분석

• 신동원

천문학 분야 RAG 파이프라인 구현 & 웹 팩토리 기능 개발

• 천승현

생명공학 분야 RAG 파이프라인 구현 & 채팅 허브 기능 개발

개발 마일스톤 (총 2주)

Phase 1

6/16 ~ 6/17

데이터 인프라 구축

3대 핵심 학술 분야 총 106,974건 대용량 데이터셋 적재 완료

Phase 2

6/18 ~ 6/26

핵심 서비스 구현

병렬 융합 RAG 채팅 허브, 비동기 문헌 분석기, 웹 팩토리 개발 완료

Phase 3

6/29 ~ 6/30

통합 검증 및 배포

전 과정 비동기 및 API 단위 테스트 수행 및 로컬 전체 시스템 배포

비즈니스 지향점 분석 (Lean Canvas)

문제 & 타겟 고객

- **핵심 문제:** 선행 문헌 조사 피로, AI 학술 환각(원문 검증 공수), IP 유출 우려
- **타겟 고객:** 석·박사 연구원, 대학 교수, R&D 센터 책임연구원, 특허 변리사

솔루션 & 가치 제안

- **솔루션:** 듀얼 트랙 병렬 RAG 스트리밍, 연구 공백 분석기, 사용자 정의 Gem
팩토리
- **가치 제안:** 학술 DB와 실시간 웹 검색의 병렬 융합, 비동기 대규모 문헌 분석
대시보드

경쟁 우위 & 핵심 지표

- **독점 우위:** pgvector HNSW 고속 검색 아키텍처, 100% 팩트 보존 번역 필터 가드
- **핵심 지표:** 세션당 대화 깊이, 연구 공백 도출 성공률, 인용 출처 CTR

비용 구조 & 수익원

- **비용 구조:** LLM API 사용료, pgvector RDS 인프라 비용, 실시간 검색 API 사용료
- **수익 구조:** Pro 멤버십 (\$19.99/월), 기업 전용 보안 On-premise 구축 패키지

시스템 아키텍처 및 대용량 데이터 관리

3-Tier 물리적 레이어 & 기술 스택

Frontend

Next.js · JavaScript · Axios · Bootstrap 5
App Router 기반 렌더링, SSE 실시간 통신 지원

Backend

FastAPI · Python 3.12 · Pydantic v2 DTO
Async ASGI 기반 스트리밍 및 SSE 브로드캐스팅

DB & Vector

PostgreSQL 17 · pgvector 0.7+ · SQLAlchemy
HNSW 인덱싱 기반 3072차원 고차원 벡터 매칭 (68ms)

AI Agent

LangGraph · LangChain · OpenAI · Tavily
asyncio.gather 병렬 LLM 오케스트레이션

대용량 ArXiv 학술 데이터 적재 현황

생명과학 q-bio.GN

54,066건

가장 큰 임베딩 공간, 유전자 편집 및 단백질 분석 최적화

천문학 astro-ph.EP

35,083건

외계행성 및 궤도역학 이론 검증용 대형 임베딩 공간

컴퓨터공학 cs.NE

17,825건

신경망 진화 및 딥러닝 핵심 개념 탐색 고속 엔진

✦ OpenAI text-embedding-3-large · 3,072차원 · HNSW cosine · avg.
68ms

병렬 융합 Q&A 채팅 허브 및 연구 공백 분석기

01

일반 채팅 허브 (Q&A Hub)

자연어 질문에 대해 논문 RAG와 실시간 웹 검색을 병렬로 구동하여 두 지식을 최적으로 융합한 답변을 실시간 스트리밍합니다.

무조건적 병렬 인출

asyncio.gather를 이용하여 DB 검색과 웹 검색을 동시 처리 — 순차 대비 평균 23% 대기 지연 감소

SSE 실시간 스트리밍

HTTP SSE 방식으로 토큰 발생 시마다 실시간 푸시, 타자 효과 마크다운 렌더링

인용 출처 매핑 & 적재

참조된 ArXiv 논문 서지 메타데이터를 1:1 인덱싱하여 chat_source 테이블에 영구 적재

02

연구 공백 분석기 (Gap Analyzer)

수십 편의 선행 연구 데이터를 배치로 분석하여, 각 문헌의 한계점을 취합하고 미개척 연구 가설을 자동 도출합니다.

비동기 BackgroundTasks

task_id 즉시 발급 후 연산을 BackgroundTasks로 오프로딩, 진행률 (10→40→80→100%) 실시간 갱신

100% 팩트 보존 번역 가드

한글 번역 과정에서 핵심 영문 인용구를 파이썬 레이어에서 백업 후 번역 완료 시 오버라이트 복원

SSE 완료 알림 & Redis 캐싱

분석 완료 즉시 SSE 브로드캐스트로 토스트 알림 노출 및 번역 결과 JSONB 캐시 영구 저장

맞춤형 AI 연구 비서 — Gem 팩토리 파이프라인

사용자가 연구 카테고리나 시스템 프롬프트(페르소나)를 조합하여 전용 연구 비서(Gem)를 개설하고, 독립된 격리 데이터 환경에서 RAG 대화를 나눌 수 있는 4단계 파이프라인입니다.

Step 1

페르소나 바인딩

사용자가 설정한 RAG 참고 분야 (CS / Bio / Astro) 및 연구 지침 시스템 프롬프트를 결합해 젼의 고유 메타데이터 레코드를 생성하고 gem 테이블에 영구 등록합니다.

Step 2

PDF 테넨시 격리

개인 연구 PDF를 업로드하면 백그라운드에서 500자 청킹 후 text-embedding-3-large로 벡터화, gem_{gem_id}_files 전용 컬렉션에 적재하여 타 사용자와 완벽히 물리 격리합니다.

Step 3

동적 도구 주입

세션 개설 시 렉시컬 스코프 내에 gem_id를 가두는 클로저(Closure) 함수를 동적으로 빌드하여 Supervisor Agent의 톨로 실시간 주입, 지정 컬렉션에서만 검색하도록 강제 제어합니다.

Step 4

물리 완전 소멸

젠 삭제 시 DB Cascade 연쇄 삭제 제약에 의해 메타데이터가 드롭되는 동시에, gem_{gem_id}_files 테이블을 'DROP TABLE' 처리하여 디스크에서 0바이트로 완전 소각합니다.

핵심 기술 문제 해결 및 리팩토링 사례

Case 01

Structured Outputs & StreamingResponse 결합

→ 이벤트 기반 NDJSON 스트리밍 도입

🚩 문제

LLM 구조화 모델은 완결된 JSON이 완성되기 전까지 토큰 단위 실시간 스트리밍이 불가능하며, 두 방식을 무리하게 혼용할 경우 타입 불일치 및 클라이언트 파싱 오류가 발생함.

✅ 해결

이벤트 기반 NDJSON 스트리밍을 구현하여 답변 본문은 즉시 토큰 단위로 전송하고, 추천 질문 및 RAG 출처 등 구조화 정보는 스트림 완료 시점에 Pydantic DTO 검증 후 최종 이벤트 라인으로 병합 전송하여 극복했습니다.

Case 02

10만 건 대용량 적재 커넥션 락업

→ 페이징 오프셋 분할 커밋 적용

🚩 문제

ArXiv 10만 건 이상의 벡터 임베딩 데이터를 단일 DB 트랜잭션으로 적재할 때, 메모리 누수와 데이터베이스 커넥션 락(Connection Lock)이 걸려 타임아웃 오류가 빈번히 일어남.

✅ 해결

5,000건 단위로 트랜잭션을 분할 및 배치 Commit하고 주기적으로 메모리를 GC 처리함으로써 106,974건의 데이터를 단 한 번의 다운타임 없이 안정적으로 적재하는 데 성공했습니다.

Case 03

번역 과정의 학술 인용구 원문 왜곡

→ Python 레이어 원문 백업/복원 가드

🚩 문제

GPT-4o 번역 단계에서 학술적으로 엄격해야 하는 원어 인용구(source_quote)들이 자연스러운 한글로 오역되거나 원어 고유 코드가 손실되어, 원문 출처를 역추적하는 신뢰성에 손상이 감.

✅ 해결

번역 전 파이썬 코드 레이어에서 핵심 인용구 배열을 복사(Backup)하고, 번역 완성 후 원어를 강제 주입(Restore)하는 하이브리드 필터를 설계하여 인용구 유실률 0%를 달성했습니다.

한계 극복 및 향후 발전 로드맵

Roadmap 01

기업용 보안 샌드박스

→ 물리 파쇄 (Shredding) 데몬 완성

한계점

보안 비서 잼 및 업로드된 PDF 파일이 런타임 ID 분리에만 의존하여, 무활동 상태에서도 디스크 및 DB에 데이터 잔재가 남아 정보 유출 취약점이 존재함.

보완 계획

- Redis TTL 만료 이벤트 감지 → 비동기 삭제 트리거
- MacOS shred 커맨드로 난수 3회 덮어쓰기 파괴
- ON DELETE CASCADE로 pgvector 임시 테이블 연쇄 파쇄

Roadmap 02

다중 에이전트 교차 검증

→ LangGraph 피어 리뷰 토론 엔진

한계점

현재 RAG 합성의 최종 조율이 단일 Synthesis 노드에서만 이루어지기 때문에 잠재적 할루시네이션 (환각) 리스크를 완전히 상쇄할 수 없음.

보완 계획

- 방법론 검증자: 가설의 논리적 모순 공격
- 신규성 분석자: 특허 RAG 대조를 통한 선행 중복도 검사
- LangGraph 순환형 그래프 — 2회 이상 피드백 패스 후 최종 합의 리포트 발행

Roadmap 03

특허 및 이중 산업 융합

→ BM25 + HNSW 하이브리드 RRF

한계점

현재 생명공학, 천문학, 컴퓨터 과학 3대 분야의 ArXiv DB로 타겟이 한정되어 있어, 특허 변리 및 타 산업군 R&D로의 실질적 도메인 확장이 필요함.

보완 계획

- BM25 키워드 검색 + HNSW 시맨틱 검색 → RRF 상호 순위 융합 노드
- Dynamic JSONB DB 스키마 로더로 무종단 도메인 유입 지원
- 법령, 특허, 신소재 등 전문 지식 레이어 순차 통합